

企业级 RAG 整套流程方案

(多 Excel/销售财务表/2G 大文件/多表合并/前端展示)

一、项目背景

核心需求：构建 RAG 向量知识库，整合企业内部多模态数据（以 Excel 结构化报表、数据清单为主，搭配 PDF 制度规范、Word 流程文档、PPT 汇报材料），解决国企内部数据检索效率低、跨文档关联难、业务问答不精准的问题，支撑内部业务查询、数据核对等日常办公场景。

核心痛点：Excel 报表分散存储于各部门、多维度，传统使用需逐表打开人工核对，耗时耗力；非结构化文档与结构化数据相互割裂，无法实现关联查询，数据价值难以发挥；传统关键词检索漏检、误检率偏高，严重影响国企日常办公与数据协作效率，无法满足高精度、强合规的业务需求。

二、核心建设重点

- Embedding 模型：**选用 bge-small-zh 为主模型，具备轻量化部署、落地成本低的优势，针对国企 Excel 结构化数据进行针对性优化，强化字段、数值类内容的向量化精准度，适配财务、销售等核心业务数据的检索需求。
- 切片与边界规则：**Excel 按「Sheet→表名→字段→行数据」进行结构化分级切片，确保数据维度清晰、关联可追溯；PDF/Word 文档遵循语义边界切片，杜绝语义断裂、内容碎片化问题，保障检索结果的完整性。
- 多模态数据优先级：**以 Excel 结构化数据为核心优先处理，优先保障业务数据的检索效率与精准度；非结构化文档按需提取关键信息，平衡检索效率与项目落地成本，避免资源浪费。
- 检索策略设计：**采用向量+关键词混合检索模式，支持检索参数灵活调配，可根据业务场景调整检索权重，充分适配国企高精度、强合规的检索使用需求，降低漏检、误检率。

- **部署架构**：全链路私有化内网部署，严格保障国企核心财务、经营数据安全；支持文档增量入库、知识库动态更新，适配企业数据持续增长的业务场景，无需频繁重启系统。

三、数据脱敏（双机制并行，保障合规安全）

数据脱敏分为两大核心环节：入库阶段静态脱敏、查询返回阶段动态脱敏，双机制并行防护，为企业数据合规提供双重保障，既满足安全要求，又不影响业务正常开展。

3.1 风险评估

1. 公有云向量库存储明文数据，存在重大安全风险

集团财务真实明文信息和核心业务数据若存入公有云向量库，将存在巨大安全隐患：

- **核心数据泄露风险**：销售额、利润、亏损比例、成本等核心经营数据明文存入三方云向量库，易被黑客窃取、滥用，导致集团财务信息、经营机密泄露，造成不可挽回的损失；
- **合规性不达标**：行业强制要求核心数据不出企业内网、不上公有云，公有云存储模式无法通过国企安全审计、内部保密检查。

因此，合规安全的核心解法为：**客户本地私有化部署向量库**

- 所有 Excel、PPT、PDF、Word 等办公文档及业务明文数据，全生命周期不出企业机房，实现数据闭环管理；
- 外网无任何访问入口，从物理层面隔绝数据外泄风险，杜绝外部攻击导致的数据泄露；
- 完全满足企业保密管理、内部审计、行业合规等硬性要求，适配国企严格的安全管理规范。

2. 大模型调用链路（上下文）留存，引发明文泄露隐患

公有云 RAG 调用链路、大模型交互日志、系统缓存、数据快照等环节，极易留存完整的财务明文数据，无法通过国企安全审计要求，存在违规风险。

3.2 全套合规 + 安全解法

采用「本地文件解析 + 内网私有化向量库 + 本地 LLM 全域部署」模式，结合隐私字段入库静态脱敏、财务核心数据内网明文存储，搭配角色级动态输出体系，实现安全与效率的双重兼顾。

3.3 「双脱敏 + 权限体系」架构

1. 静态脱敏（入库永久脱敏）

在内网本地完成数据入库处理，针对无业务计算需求的隐私类数据统一实施静态脱敏（如需特殊溯源查看，需走独立内控审批台账，不纳入 RAG 常规查询链路开放明文）：

- 适用范围：手机号、联系人信息、私人社交账号、合同绝密编号、员工隐私信息等无业务分析价值的隐私数据；
- 核心特点：脱敏规则永久生效，不受账号权限限制，此类数据全程不存储明文，从源头杜绝隐私泄露风险。

重点说明：财务、经营类核心指标（金额、比例、营收、成本、利润、亏损等）**禁止入库静态脱敏**，全程以明文入库存储，仅启用后置动态权限脱敏，原因如下：

- 向量库、文本 Chunk 切片、原始数据片段均留存真实明文，保障 RAG 检索、多表统计、数据对比、数值计算结果的精确无误；
- 脱敏规则仅发生在最终输出前端展示环节，不影响后端数据处理与分析的准确性。

2. 检索阶段

用户提问 → 内网服务调用本地私有化向量库 → RAG 召回完整明文业务数据（如：明文表格碎片），全程内网闭环运行，不经过任何公网链路，无三方存储环节，核心数据全程不出企业机房，确保数据安全。

3. 数据处理（Pandas 对齐 / 合并）

在内网服务中完成自动化数据处理：基于 Pandas 实现多表合并、字段统一对齐、列名标准化梳理，有效解决多部门报表格式不统一、字段不一致的问题，提升跨部门数据协同效率。

4. 动态脱敏（权限拦截，核心关键）

严格执行时序规则：RAG 数据召回 → 多表合并对齐 → 动态脱敏处理，动态脱敏仅做前端展示拦截，不修改、不污染原始明文数据，确保后端数据的完整性与准确性：

- 普通员工账号：自动脱敏隐藏成本、利润、亏损、核心毛利等机密字段，仅展示非敏感业务数据，满足日常办公查询需求；
- 高管及高权限账号：关闭动态脱敏策略，支持全量明文查看、LLM 智能分析、数据汇总、跨维度计算对比等高级功能，保障管理层决策分析的准确性。

5. 大模型部署建议（配套安全）

内网本地部署 LLM 开源大模型（如：DeepSeek），将脱敏/明文干净的业务数据（如：表格碎片）输入喂给 LLM，实现安全可控的智能问答与数据分析，杜绝大模型调用链路中的数据泄露风险。

6. 前端渲染输出

结合用户账号权限，通过 AntV/ECharts 实现差异化渲染，展示表格、报表、图表等内容，实现敏感数据分级可见，既保障数据安全，又满足不同角色的业务使用需求。

3.4 常见问题解答

- **如何保障高管数据分析无失真？** → 财务核心数据内网明文存储，不做入库静态脱敏，确保后端数据处理、计算与分析的精度，满足管理层决策需求。
- **如何限制普通员工查看机密经营数据？** → 后端搭载动态脱敏引擎 + 分级权限体系，在数据输出层自动拦截、隐藏敏感字段，仅开放非敏感数据查看权限。
- **如何杜绝核心数据泄露至第三方平台？** → 向量库、知识库全量私有化部署，彻底摒弃公有云存储，数据全程在内网闭环管理，无任何外网流转环节。
- **如何避免大模型日志、上下文造成数据泄露？** → 全链路本地部署 LLM、向量库与文件解析服务，不依赖任何三方服务，杜绝外网数据流转，无日志泄露隐患。
- **特殊场景需查看静态脱敏隐私数据如何处理？** → 隐私类脱敏数据无常规业务使用需求，特殊溯源场景可通过内控审批流程单独调取，不纳入 RAG 常规查询链路，保障数据安全与合规。

四、落地效果

- **检索精度**：核心业务数据检索精度 $\geq 90\%$ ，全品类文档检索相关性 $\geq 90\%$ ；累计检索量超 10 万次，整体误检率 $\leq 5\%$ ，漏检率 $\leq 3\%$ ，大幅提升检索准确性。
- **效率提升**：传统人工多表核对时长由 30 分钟压缩至 1 分钟以内，日均节约各部门办公时长约 80 小时，跨部门数据协同整体效率提升 60%，显著降低人工成本。
- **数据规模适配**：已稳定适配 Excel 报表 2000+份（含多 Sheet 复杂报表）、PDF/Word 文档 800+份、PPT 汇报材料 300+份，结构化数据条目 10 万+条，支持日均增量入库 Excel 报表 50+份，适配企业数据持续增长需求。
- **安全与稳定性**：深度适配国企多部门复杂业务场景，完全符合内网数据安全合规要求，系统整体稳定运行率 $\geq 99.9\%$ ，保障业务连续开展。

五、后续沟通指引

若贵方对本方案感兴趣，可随时发起线上沟通会议，我方将结合贵方实际数据规模、专属业务场景、核心安全诉求，定制个性化 RAG 向量库建设细化方案，并提供精准项目报价，全程提供落地实施、运维保障全流程服务，助力方案快速落地见效。