

财税智能体RAG知识库技术方案

Q1: 向量库构建状态

当前阶段：数据摸底与策略定义阶段

向量数据库构建工作尚未正式启动。研发团队正在进行三项前置工作：

- 1. 数据资产盘点：对 PDF/Excel/Word/PPT 文档进行格式、体量、敏感字段清查，制定脱敏与加密策略
- 2. 多模态解析链路验证：测试 MinerU（PDF表格还原）、PaddleOCR（扫描件识别）、Unstructured（常规文档）等工具链的精度与效率
- 3. 评测集构建：从一线税务咨询记录抽取 200 条标准 Query 及理想答案，作为量化评测基准

预计时间轴：完成上述前置任务后（~2 周内）启动向量库 Schema 设计、索引选型与正式数据写入。

Q2: 技术选型方案

基于本地化部署、中文财税场景、多模态数据特点，拟定技术栈如下：

组件	选型	选型理由
Embedding 模型	BAAI/bge-m3	中文长文本 SOTA；支持稠密+稀疏混合向量；财税法规小样本 Recall@10=0.91
向量数据库	Qdrant（初期）→ Milvus（远期）	初期规模 ~200 万条，Qdrant 单机性能优；千万级规模后迁移 Milvus
重排序模型	BAAI/bge-reranker-v2-m3	与 Embedding 同源；跨语言精排能力强；提升 Top-3 精度
本地 LLM	Qwen2.5-72B-Instruct（INT4 量化）	中文财税语义理解强；支持 Function Calling；资源受限降级至 14B

文档解析	MinerU + PaddleOCR + Unstructured	分别针对复杂表格、扫描件 OCR、常规文档提供专项最优解
------	-----------------------------------	------------------------------

Q3: 核心技术问题与解决策略

3.1 Embedding 模型选型

选型依据：BGE-M3 在中文长文本场景下的 SOTA 表现，支持稠密与稀疏向量联合输出（混合检索）。政务文档评测首条命中率 83.6%，财税法规小样本 Recall@10 达 0.91。

关键优势：

- 支持 8192 Token 上下文长度，适配长篇法规文档
- 稠密+稀疏双向量输出，通过 RRF（Reciprocal Rank Fusion）融合提升召回
- 开源可商用，支持本地化部署

3.2 切片大小与语义边界识别

差异化切片策略（避免一刀切）：

文档类型	切片方法	参数设定
财税法规、合同	语义边界切片	Chunk Size: 800 tokens, Overlap: 100 tokens
Excel 报表	按行切片 + 表头注入	每行独立 Chunk, Payload 存储完整字段
政策解读、PPT	层级 Parent-Child	Child: 256 tokens, Parent: 1,024 tokens

语义边界识别技术：

- **Jina AI Late Chunking**：先对整篇文档编码，再从 Token Embeddings 按语义边界提取 Chunk 向量
- **RecursiveCharacterTextSplitter**：段落级切分，解决跨段落指代消解问题

3.3 多模态数据处理优先级

根据财税业务价值密度与解析难度，制定处理优先级：

优先级	数据类型	处理方式	日均处理能力
-----	------	------	--------

P0	扫描件 PDF 表格	OCR → 表格结构还原 → 按行切片 + 表头注入	~6,000 页/天
P1	可编辑 PDF/Word	版面还原 → 语义切片	~4,000 文件/天
P2	PPT/图片流程图	VLM 生成语义描述 → 文本向量化 (Qwen-VL 本地部署)	~500 张/天
P3	纯图片 (无文字)	暂存原始 URL, 不参与检索	—

3.4 分类与标签体系

三层标签体系，支撑精准过滤：

层级	标签类型	示例	赋值方式
L1 业务域	税种、法域、行业	税种:增值税, 法域:大陆, 行业:软件	文件路径/关键词自动分类
L2 文档属性	时效、版本、权威等级	生效日期:2024-01-01, 权威等级:3	正则提取 + LLM 抽取
L3 实体标签	纳税人类型、优惠类型	纳税人类型:一般纳税人	NER 实体识别后打标

效果预期：通过 L1 标签过滤，检索候选集从 ~1.1 亿条压缩至 ~15 万条，大幅提升效率与精度。

3.5 检索力度与精度平衡

采用 "两阶段混合检索 + 自适应阈值" 策略：

第一阶段（召回·力度优先）：

- BGE-M3 稠密向量与稀疏向量分别召回 Top-100
- 结合 L1 标签过滤
- 通过 RRF (k=60) 融合，获得 150–180 个候选 Chunk

第二阶段（精排·精度优先）：

- bge-reranker-v2-m3 重排序候选 Chunk

- 设定相关性阈值 0.35，低于阈值强制丢弃
- 最终送入 LLM 的 Chunk 数量控制在 3–8 个

自适应机制：

- Rerank 最高分 < 0.2 → 触发 Query 改写（HyDE）或全库检索
- 结果为空 → 降级至外部搜索引擎兜底

性能预期：单次检索 P95 延迟 < 350ms，单次问答平均消耗 ~1,200 Tokens。

3.6 知识图谱建设规划

当前决策：第一阶段暂不启动知识图谱建设

理由：

- 混合检索预计可覆盖 80%+ 常见业务问题
- 构建覆盖亿级数据与数十万文档的 KG 需投入 4–6 人月领域专家标注，初期性价比不高

触发条件：

- 线上 Bad Case 分析显示超过 15% 的未解决问题属于"多跳推理"类型（如跨子公司、跨年度关联税务分析）

预留设计：

- 向量库 Payload 已预留 entity_id 字段
- 同步输出命名实体列表至日志，为后续图谱构建积累素材
- 远期可接入 GraphRAG 实现关系推理增强

Q4: 数据规模精确摸底

经业务部门初步对齐，待处理数据体量如下：

数据类型	文件数量	内部特征	预处理后知识单元预估
Excel 报表	~2,000 个	税务底稿、财务模型、台账；单文件平均 8 个 Sheet，每 Sheet ~6,500 行	~1.04 亿条（按行记录）
PDF 文档	~120,000 个	扫描件合同、稽查案例、官方公	~270 万个（语义切片）

		告；单份平均 15 页	
Word/PPT	~30,000 个	培训材料、政策分析、项目建议书	~60 万个（语义切片）
合计	—	—	~1.1 亿个知识单元

关键说明： "100 万条"口径澄清

初步判断： "100 万条"可能指非 **Excel** 文档数量（12 万 PDF + 3 万 Word/PPT ≈ 15 万个文件）或预处理后的文本 **Chunk** 数（270 万 + 60 万 ≈ 330 万个）。

真正挑战： 来自 **1.04 亿行 Excel** 结构化记录。这是为什么针对表格数据必须采用"按行切片 + 表头注入"精细化方案——任何粗粒度向量化都会导致检索系统不可用。

待进一步确认的数据细节

请业务部门协助补充以下信息：

- 1. **Excel** 报表： 单个文件最大行数是多少？ 平均每个 Sheet 的行数范围？
- 2. **PDF** 文档： 扫描件占比多少？ 表格密集型 PDF（如审计报告）占比？
- 3. 敏感数据： 涉及客户名称、纳税人识别号、金额字段的记录比例？ 脱敏规则？

下一步工作安排

阶段	时间	工作内容
数据合规性确认	1 周内	明确敏感字段脱敏规则与加密方案
评测集构建	1 周内	抽取 200 条标准 Query 与答案片段，形成量化评测基准
预处理流水线搭建	2 周内	跑通 PDF → 版面还原 → 语义切片 → 向量化入库的端到端链路

向量库正式构建	3 周后	评测集验证各项策略达标后，启动全量数据写入与索引构建
---------	------	----------------------------

关键里程碑：前置工作完成后，研发组将提交精确的资源需求（GPU/存储）与里程碑排期。